面向跨人员泛化的智能手机人体活动识别与特征压缩研究

作者姓名（待填写）

（学校、学院及邮编待填写；学号待填写；课程：机器学习）

摘　要　针对智能手机人体活动识别中人员依赖评价偏差以及特征压缩未必降低整体开销的问题，在 UCI HAR 官方 21 名训练人员与 9 名测试人员隔离的条件下，比较支持向量机、随机森林、逻辑回归、K 近邻和 Fisher 线性判别分析。采用全 561 维、主成分分析和 ANOVA 筛选三条路径，在训练人员五折验证中评估 480 个候选，按相对全特征 Macro-F1 下降不超过 1 个百分点的规则选择压缩维数。锁定配置后测量分类成绩、逐人员表现、模型体积，并在 1、32、256、2947 窗口批量下分别测量标准化、变换、分类与完整预测。结果表明，全特征 FisherLDA 的测试准确率与 Macro-F1 分别为 96.23%和 96.26%。在 2947 窗口批量下，PCA 相对同分类器全特征的预测加速比分别为 SVM 的 2.21 和 KNN 的 2.58，但其余方案中共有 3 个分类器的 PCA 完整预测变慢。压缩收益依赖分类机制与批量规模，验证达标不保证新人员测试达标。研究支持将预测性能、人员差异和完整管线成本联合评价，而非仅根据维数下降推断轻量化成功。

关键词　人体活动识别；跨人员泛化；主成分分析；特征选择；线性判别分析；预测开销

Cross-Subject Smartphone Human Activity Recognition and Feature Compression

Author and affiliation to be completed

Abstract　Smartphone human activity recognition requires both reliable predictions for previously unseen people and a realistic assessment of computational cost. A smaller feature vector does not necessarily imply a faster deployed prediction pipeline, because a learned transformation must itself be executed. This study compares RBF support vector machines, random forests, logistic regression, k-nearest neighbors, and Fisher-type linear discriminant analysis on the official UCI HAR subject-disjoint split. The training partition contains 7,352 windows from 21 participants, while the test partition contains 2,947 windows from nine different participants. The supplied 561-dimensional engineered features are used directly; raw inertial feature extraction is outside the measured scope. For each classifier, full features are compared with principal component analysis and ANOVA-based feature selection. Seven compressed dimensions, 20, 50, 100, 150, 200, 250, and 300, are evaluated. All newly fitted preprocessing is restricted to the training subjects of each fold. The complete search consists of 480 configurations and 2,400 grouped cross-validation fits. For each compression route, the smallest evaluated dimension whose mean validation macro-F1 is within one percentage point of the tuned full-feature baseline is selected. If no dimension qualifies, the best validation configuration is retained explicitly as a failed diagnostic route rather than silently accepted. All final configurations are locked before loading the test arrays. A separate fixed-parameter comparison illustrates the difference between random-window and subject-grouped evaluation without attributing the entire gap to a single causal factor. In addition to aggregate and per-participant classification metrics, complete saved-pipeline size and prediction cost are recorded. Timing uses one computational thread, three warm-up calls, and 15 interleaved repetitions at batch sizes of 1, 32, 256, and 2,947. Standardization, dimensional transformation, classifier prediction, and complete-pipeline prediction are measured separately. Independently measured stage medians are not treated as an exact additive decomposition. The full-feature FisherLDA obtains 96.23% accuracy and 96.26% macro-F1 on the fixed test participants. At the largest batch size, PCA yields speedup ratios of 2.21 for SVM and 2.58 for KNN relative to their own full-feature baselines; PCA increases complete prediction time for 3 of the five classifiers. The findings indicate that feature compression is a classifier-dependent performance–cost trade-off, not a universally beneficial acceleration step. The study preserves unsuccessful configurations and individual-participant variation. Because the same official test set was examined in earlier project iterations, this rerun is an exploratory extension rather than a new independent confirmation. No claims are made about statistical superiority across all users, raw-signal extraction savings, mobile-device power consumption, or cross-device generalization.

Keywords　human activity recognition; cross-subject generalization; principal component analysis; feature selection; linear discriminant analysis; prediction cost

1 引言

基于智能手机惯性传感器的人体活动识别，可以把连续运动信号转化为离散的活动类别。与图像识别不同，该任务不需要直接采集用户外观，而是使用加速度、角速度等信号描述运动状态。UCI HAR 通过标准化采集协议提供了六类日常活动及其窗口特征，为比较经典分类器建立了可复用基础[1-2]。本文关注的不是增加一个分类器后能否获得更高的排行榜分数，而是模型在未见人员上是否可靠，以及减少特征后是否真正降低计算开销。

这两个问题不能用普通随机划分和维数统计替代。对于同一人员连续产生的窗口，训练样本与验证样本可能共享人员习惯和局部信号结构。UCI HAR 的相邻窗口存在重叠，把所有窗口打散得到的高分不必然代表对新人员的泛化能力；已有研究讨论了重叠窗口与验证协议对评价结果的影响[3]。因此，划分单位应与预期使用对象一致：若目标是未见用户，人员而不是单个窗口才是隔离单位。

特征压缩也存在容易被忽略的代价。主成分分析（principal component analysis，PCA）能够构造较低维的表示[4]，特征选择则保留一部分原始变量[5]。但是，PCA 预测时需要额外执行投影；对于本来只需较小线性运算的分类器，投影开销可能超过分类阶段节省的运算。因而“561 维降至 200 维”本身既不能证明加速，也不能证明分类性能保持。

基于上述考虑，本文提出三个实验问题：R1，按人员隔离与随机窗口验证得到的分数有何差异，整体结果是否掩盖人员差异；R2，PCA 与 ANOVA 筛选在不同分类器上能否保持接近全特征基准的性能；R3，在计入标准化、变换与分类后，压缩收益是否依赖分类器及预测批量。实验采用 scikit-learn 实现[6]，对五个分类器、三条特征路径进行统一人员分组调参，并在测试前锁定参数及维数。

本文的工作是可复现的课程比较研究，不提出新的 PCA、Fisher 判别或特征选择算法。主要工作体现在统一的人员隔离协议、可追溯的维数选择规则，以及完整预测与分阶段开销的联合分析。所有结果来自本次重新运行；未达标、测试损失超标以及降维后变慢的配置均保留。

2 相关工作与研究定位

2.1 活动识别数据与人员独立评价

Anguita 等构建了基于腰部智能手机的公开活动识别数据集，并给出了特征工程与分类基线[1]。官方版本按照参与者而非窗口随机划分训练、测试部分[2]。本文沿用这一划分，不重新寻找对模型更有利的测试人员，也不把官方文献成绩当成本项目复现成绩。

Dehghani 等分析了惯性传感器活动识别中重叠窗口的评价问题[3]。本文据此设置训练集内部的验证协议对照：固定分类器参数，只改变随机窗口划分与人员分组划分。该对照用于刻画两种评价目标的区别；由于验证样本、训练样本数量与人员组成同时不同，分数差不解释为“人员泄漏”的纯因果效应。

2.2 特征提取与特征选择的差异

PCA 通过方差最大的正交方向表达数据，是无监督线性特征提取方法；保留较多方差并不保证保留最适合分类的方向[4]。ANOVA 筛选属于单变量过滤方法，它按照各特征的类别区分统计量排序，不构造新的综合变量。变量筛选的方法种类很多，其目标与约束也不相同[5]。本文采用 ANOVA 是为了提供计算较低、可解释且能精确指定保留数量的对照，不是因为已经证明它优于互信息、递归消除或稀疏模型。后几类方法未在本次运行，不作为已完成贡献。

2.3 不同分类机制下的压缩收益

支持向量机通过间隔准则建立分类边界[7]，随机森林组合多棵随机化决策树[8]，近邻方法根据参考样本的距离关系预测[9]，Fisher 思想及线性判别分析提供类间分离与类内散布的线性基线[10]。逻辑回归则以正则化的线性判别分数估计类别概率[11]。本文选择这五类方法，是为了覆盖核模型、树集成、距离模型和线性模型，而不是追求最多的算法数量。

研究的主要增量是将“压缩后的分类表现”与“执行压缩自身的计算代价”放在同一协议下评价。本文既报告每种模型的完整输入基准，也报告压缩路线的失败情况，并区分总体窗口指标、人员等权指标和不同批量的实现开销。

3 方法与评价协议

3.1 问题定义与人员隔离

记样本集合为 $D=\{(x_i,y_i,g_i)\}$，其中 $x_i\in R^{561}$ 为官方窗口特征，$y_i\in\{1,\dots,6\}$为活动标签，g_i 为人员编号。官方训练人员集合与测试人员集合不相交。训练集内部采用 StratifiedGroupKFold 生成五折，在尽量保持类别比例的同时，使每名人员只属于一个验证折[12]。各模型和全部候选共用同一折分配，人员编号只用于分组与事后评价，不进入输入矩阵。

$$G_{tr}\cap G_{te}=\varnothing,\qquad G_{tr}^{(f)}\cap G_{va}^{(f)}=\varnothing。\tag{1}$$

本项目新增的标准化、PCA 和特征选择均放在折内训练流程中。标准化参数只由当前训练人员计算；验证与测试样本使用已经拟合的变换器。此设置避免先用全数据计算变换再交叉验证的预处理泄漏[13]。官方特征文件本身已经经过上游特征提取和归一化，本研究不据此声称审计了原始信号处理的全部步骤。

$$z_{ij}=(x_{ij}-\mu_{j,tr})/\sigma_{j,tr}。\tag{2}$$

3.2 三条特征表示路径

全特征路径只标准化并保留 561 列，构成每个分类器自己的基准。PCA 路径在标准化后，用完整奇异值分解拟合最大候选维数的主成分，取前 k 个方向构造表示，不使用白化。若 W_k 为对应投影矩阵，则预测变换为式(3)。不同分类器复用同一训练折的变换结果，但每个分类器参数组合仍分别拟合。

$$Z_k=(Z-\mu_{pca})\,W_k,\qquad W_k^{T}W_k=I_k。\tag{3}$$

ANOVA 路径使用 SelectKBest(f_classif)。设第 c 类含 n_c条训练记录，第 j 个特征的类均值为 μ_{cj}、全体均值为 μ_j，其排序分数是类间均方与类内均方的比值。本文仅使用 F 分数排序，不把重叠窗口上的 p 值当作可靠的显著性证据；它也不自动消除所选特征之间的冗余。

$$F_j=[\Sigma_c\, n_c(\mu_{cj}-\mu_j)^2/(C-1)]\tag{4a}$$

$$/\,[\Sigma_c\,\Sigma_{i\in c}(z_{ij}-\mu_{cj})^2/(N-C)]。\tag{4b}$$

PCA 与 ANOVA 均考察 20、50、100、150、200、250、300 维。所有候选在运行前写入冻结配置，各模型使用相同的候选维数，不依据本轮测试分数追加搜索。PCA 输出是原始变量的组合，而 ANOVA 输出是原始列的子集，二者的物理解释和部署开销不同。

3.3 分类器与超参数

RBF-SVM 使用核函数 $K(x,x')=\exp(-\gamma\|x-x'\|^2)$，搜索正则化参数 C 与 γ。RandomForest 固定 200 棵树，调节最大深度和叶节点最少样本数，预测时聚合树的类别概率。其 max_features 固定为 sqrt，因此特征维数变化也会改变每次分裂可考察的变量数。

LogisticRegression 使用 L2 正则化、lbfgs 求解器和最大 8000 次迭代，搜索 C。KNN 使用暴力欧氏距离搜索，比较邻居数和普通/距离加权投票。FisherLDA 使用多类 LinearDiscriminantAnalysis，固定 lsqr 求解器，比较无收缩、自动收缩及三个指定收缩强度；先验由训练折类别比例估计。该模型在本项目中作为分类器，而非额外的监督降维器[14]。

LDA 假设各类别共享协方差，分类可用线性判别分数表示为式(5)，Σ†表示广义逆或等价的最小二乘解；数值实现不显式求矩阵逆。六分类 LDA 的判别投影最多有五个方向，与 PCA 的 20～300 维不是同一个概念。这里不调用 LDA.transform，也不把 200 维 PCA 误解释为 200 维 Fisher 投影。

$$\delta_c(z)=z^{T}\Sigma^{\dagger}\mu_c-\tfrac{1}{2}\mu_c^{T}\Sigma^{\dagger}\mu_c+\ln\pi_c。\tag{5}$$

3.4 训练内选择与失败方案保留

对模型 m、特征方法 r、维数 k 和分类器参数 θ，先计算五个验证折 Macro-F1 的算术平均。每个维数分别搜索相同模型网格，不只给压缩路线调参而不给全特征基准调参。记每个维数内的最高平均分为 $S_{m,r}(k)$，全特征最优分数为 B_m，选维数规则为式(6)，其中 ε=0.01。

$$k^{*}=\min\{k\in K: S_{m,r}(k)\ge B_m-\varepsilon\}。\tag{6}$$

若集合为空，保留验证分数最高的配置用于诊断，并将“验证达标”标记为否；不能把它当成成功压缩。相同分数按固定候选编号处理，不根据测试成绩打破平局。验证分数参与开发期选择，存在选择乐观性；本项目未进行外层嵌套人员交叉验证。所有 15 个最终配置先写入 selection_lock.json，再用完整训练集重新拟合，之后才读取测试数组。

3.5 分类与资源评价指标

总体分类表现报告 Accuracy、六类 Macro-F1 和平衡准确率，同时保存逐类精确率、召回率与混淆矩阵。Macro-F1 按类别等权，如式(7)；人员等权指标则先为每名测试人员分别计算六类 Macro-F1，再取九人的平均，如式(8)。二者不同，不能用总体高分代替对每名用户的检查。

$$F_1,\mathrm{macro} = (1/C)\ \Sigma_c\ 2P_cR_c/(P_c+R_c)。 \quad (7)$$

$$F_1,\mathrm{person} = (1/9)\ \Sigma_{s=1}^{9}\ F_1,\mathrm{macro}^{(s)}。 \quad (8)$$

预测资源评价区分完整调用和独立阶段调用。批量 B 的完整时间为一次 Pipeline.predict 的墙钟时间；对 15 次测量取中位数，再除以 B 得到每窗口平均耗时。相同分类器的全特征/PCA 耗时比定义为加速比，大于 1 才表示 PCA 更快。模型大小使用统一压缩等级保存的完整 Pipeline 文件字节数，不将其解释为峰值内存。

$$\bar{t}(B)=\mathrm{median}_r\ T_r(B)/B, \quad (9a)$$

$$\mathrm{Speedup}(B)=\bar{t}\mathrm{full}(B)/\bar{t}\mathrm{PCA}(B)。 \quad (9b)$$

分别测量标准化、压缩变换、分类预测和完整流程，阶段输入在计时前准备。独立阶段的中位数不可严格相加为完整流程中位数，因为调用、校验、缓存和分配状态不同。预测批量、模型复杂度及数据表示都会影响实际延迟[15]。本文保持默认输入校验，不通过关闭安全检查制造速度收益。

4 实验设置与复现实现

4.1 数据集与任务范围

使用 UCI HAR 官方 561 维特征版本：30 名 19～48 岁志愿者佩戴腰部 Samsung Galaxy SII，采集三轴加速度计和陀螺仪信号；采样频率 50 Hz，窗口长 2.56 s，相邻窗口重叠 50%[1-2]。六类分别为行走、上楼、下楼、坐、站立和躺卧。本项目不重新提取原始惯性特征，不开发手机端应用，也不把本任务称为跌倒检测或疾病诊断。

训练集有 7,352 个窗口、21 名人员，测试集有 2,947 个窗口、9 名人员。两部分人员交集为 0。程序按原始列编号保留全部 561 列，重复特征名称不导致删列；输入文件逐项保存 SHA-256。类别数量见表 1。

表 1　官方人员划分中的窗口样本数

活动类别	训练集	测试集
行走	1226	496
上楼	1073	471
下楼	986	420
坐	1286	491
站立	1374	532
躺卧	1407	537
合计	7352	2947

4.2 参数预算与固定对照

随机种子统一为 42。每模型有 15 种特征设置，即全特征 1 种、PCA7 种、ANOVA7 种。每种设置分别评估 SVM 8 组、RF 6 组、LR 5 组、KNN 8 组、LDA 5 组参数，共 480 个候选、2400 次主要五折拟合。树数量固定而非搜索；网格规模有限，最优参数碰到边界只作诊断，不在看过测试成绩后自动扩大。表 2 给出搜索范围。

表 2　每种特征设置下的分类器搜索空间

模型	候选参数	组数
SVM	C=1,10,100,1000；γ=scale,0.001	8
RF	深度=None,10,20；叶节点最少样本=1,3	6
LR	C=0.01,0.1,1,10,100	5
KNN	邻居=3,5,9,15；权重=uniform,distance	8
LDA	收缩=None,auto,0.05,0.2,0.5	5

另在训练人员中固定参数，比较随机窗口分层五折与人员分组五折，共 50 次拟合。固定参数为 SVM 的 C=10、γ=scale；RF 默认不限深度且叶节点最少样本 1；LR 的 C=1；KNN 的 5 邻居普通投票；LDA 无收缩。压缩曲线还提供从已评估候选提取的固定参数对照，其中 SVM 固定 C=10、γ=0.001；它与上述验证协议对照的 γ=scale 不是同

一实验，不跨表相减。该对照用于区分逐维数重新调参与表示变化，不能完成纯因果归因。

4.3 测时环境与四种批量

本轮在 Linux x86-64 环境运行，处理器报告为 AMD EPYC 9V74，容器可用 5 个逻辑 CPU；Python 3.13.5、NumPy 2.3.5、SciPy 1.17.0、scikit-learn 1.8.0。搜索使用 4 个进程，底层 BLAS/OpenMP 限制为单线程；正式预测计时不与网格拟合并行。软件版本和线程池信息随结果保存。虚拟化机器的负载会影响计时，不宣称跨设备绝对延迟保证。

为分析特征变换自身的代价，分别对 B∈{1,32,256,2947}测量四阶段，预热 3 次、重复 15 次，交错模型及阶段顺序；所有原始计时保存而非只报最佳一轮。输入按固定均匀索引选择，B=1 仅取测试窗口 0，属于控制微基准，不能代表所有在线用户。原流程另保留 64 个均匀位置单窗口调用的总体平均计时，两种口径不混用。

阶段统计共 3600 条原始记录、240 行汇总；全特征路线不存在压缩操作，其 reduce=0 为结构性缺省而非实测零延迟。逐批量比较拆解后的预测与完整 Pipeline 是否一致。输出均值、分位数和速度比可从原始记录复算。初始特征提取、磁盘读取、模型加载与手机功耗不在测量范围内。

4.4 不确定性与证据保存

对于压缩相对全特征的人员 Macro-F1 差值，以测试人员为单位进行 2000 次配对 Bootstrap，取 2.5%与 97.5%分位数作为描述性区间。重叠窗口不作为独立重采样单位；只有九名人员且训练模型固定，因此区间不覆盖训练人员重抽样和新地区人群变化，也不作为总体非劣效性的证明。

保留全部候选与逐折分数、训练验证人员索引、测试真值和预测、配置锁、模型文件哈希、完整及分阶段计时。训练入口从空断点重新开始，不混用上传包的旧计时。单元测试验证软件接口与规则，结果核验则独立复算预测指标，二者均不替代外部数据确认。

5 分类结果与跨人员分析

5.1 最终配置的总体表现

本轮从空检查点完成 480 个候选的 2400 次五折拟合，并将 15 条管线用于官方测试人员。表 3 将验证选择与测试评价分别列出；ΔF1 始终相对于同一分类器的全特征基准，单位为百分点。全特征 FisherLDA 在五个全特征模型中取得最高测试 Macro-F1，为 96.26%，准确率为 96.23%。这只是本次固定测试人员上的观察，未证明该模型在所有人群上具有统计显著优势。

表 3 训练内锁定方案与官方测试集结果（分数单位：%）

模型	特征方案	维数	验证 F1	验证达标	测试 Acc.	测试 F1	ΔF1(pp)
SVM	全特征	561	93.568	基准	95.52	95.46	—
SVM	PCA	150	93.030	是	94.37	94.27	-1.19
SVM	ANOVA	200	93.556	是	93.62	93.60	-1.86
RF	全特征	561	90.215	基准	92.77	92.56	—
RF	PCA	200	86.456	否	89.18	88.77	-3.79
RF	ANOVA	200	89.658	是	90.06	89.84	-2.71
LR	全特征	561	93.498	基准	95.52	95.50	—
LR	PCA	200	93.169	是	94.54	94.54	-0.96
LR	ANOVA	200	93.041	是	93.65	93.77	-1.74
KNN	全特征	561	88.015	基准	89.04	88.69	—
KNN	PCA	150	87.496	是	88.80	88.46	-0.23
KNN	ANOVA	100	87.459	是	87.34	86.90	-1.78
LDA	全特征	561	94.952	基准	96.23	96.26	—
LDA	PCA	300	93.935	否	95.96	95.95	-0.31
LDA	ANOVA	200	93.870	否	93.62	93.61	-2.65

注：SVM、RF、LR、LDA 分别表示 RBF-SVM、随机森林、逻辑回归、FisherLDA。验证达标仅指训练人员验证分数达到预设范围，不是最终测试或统计非劣效性结论。失败路线按原规则保留。来源：selected_configs.csv、test_metrics.csv。

十条压缩路线中，7 条在训练验证中达标，3 条未达标。未达标路线为 RF-PCA、LDA-PCA、LDA-ANOVA。这些方案不因最终测试成绩较好而重新标为验证成功。另一方面，测试损失超过 1 个百分点的方案也不能以“先前验证通过”为理由忽略；验证目标与测试观察需要分开报告。

PCA 路线中，SVM、LR、KNN 和 LDA 分别选取 150、200、150 和 300 维。SVM 的测试 Macro-F1 相对全特征变化-1.19 个百分点；KNN 变化-0.23 个百分点。因而本实验不支持“压缩统一提高分类准确率”的命题。不同表示对分类器的影响并不一致，后文还需结合资源开销判断是否值得采用。

5.2 维数选择与 Fisher 收缩参数

图 1 和图 2 分别给出 SVM、FisherLDA 的人员分组验证曲线。曲线每一点是该维数内部参数搜索的最高平均 Macro-F1，误差线是对应配置的折间标准差，而不是置信区间。图中的全特征基准和容忍下限与选维数规则一一对应。

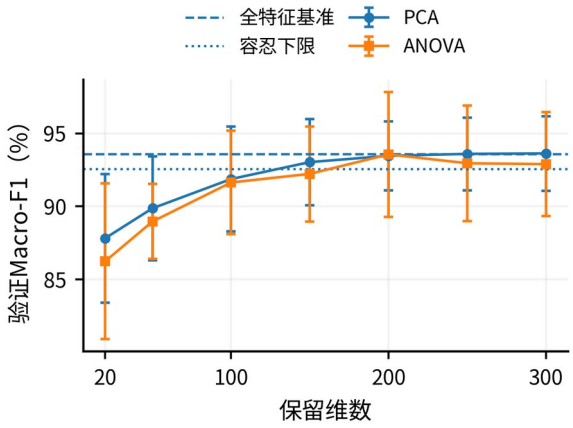


图 1 SVM 的训练人员验证维数曲线

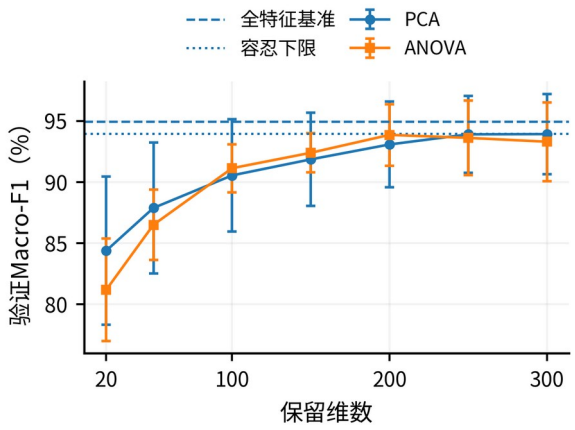


图 2　FisherLDA 的训练人员验证维数曲线

RBF_SVM 的全特征验证 Macro-F1 为 93.568%，容忍下限为 92.568%。新增 250 维的最佳验证分数为 93.593%，最终 PCA 选择 150 维，验证状态为达标。这是当前候选集合内的选择，不代表找到了连续意义或所有整数维数中的全局最小维数。

FisherLDA 的全特征验证 Macro-F1 为 94.952%，容忍下限为 93.952%。新增 250 维的最佳验证分数为 93.914%，最终 PCA 选择 300 维，验证状态为未达标。这是当前候选集合内的选择，不代表找到了连续意义或所有整数维数中的全局最小维数。

在完整训练集重新拟合后，SVM 选定 PCA 表示保留的累计方差比例为 98.11%，FisherLDA 选定 PCA 表示为 99.91%。这些方差比例用于描述表示，不是本实验选维数的准则；较高方差保留不能替代类别判别或未见人员的实际测试。

表 4　全特征 FisherLDA 的收缩调参

收缩设置	验证 F1(%)	折间标准差
None	94.952	2.428
auto	94.285	3.004
0.05	93.908	3.354
0.2	93.343	3.546
0.5	92.169	4.137

全特征 FisherLDA 最终选择 shrinkage=None。比较收缩候选的意义，是检验本数据、缩放与验证协议下是否需要正则化协方差，而不是预设收缩越强越好。若无收缩最好，也属于调参产生的有效结果；它不能证明数据严格满足各类同协方差的高斯假设。

固定参数与逐维数调参的分数差保存在 fixed_parameter_comparison.csv。例如，各模型在全部特征设置中最大的开发期调参差值分别为 SVM 7.24 个百分点、RF 0.47 个百分点、LR 0.96 个百分点、KNN 1.67 个百分点、LDA 0.16 个百分点。这些差值只描述同一批训练验证记录中的配置选择，存在选择乐观性；不能直接写成独立测试集上的调参收益。

5.3　验证协议对照

表 5　固定参数下两种验证协议的 Macro-F1

模型	随机窗口(%)	人员分组(%)	差值(pp)
SVM	98.84	92.89	5.95
RF	98.18	90.08	8.11
LR	98.58	93.50	5.08
KNN	96.23	86.41	9.82
LDA	98.26	94.95	3.31

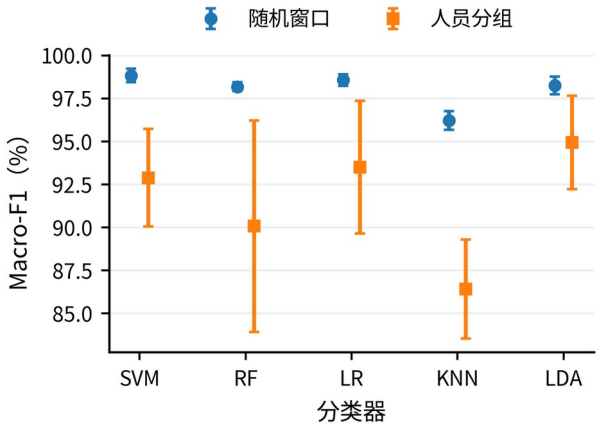


图 3　随机窗口与人员分组验证对照

随机窗口划分与人员分组验证的结果不应混在同一“模型泛化能力”排行榜中。前者允许验证窗口来自训练见过的人员，后者要求面对当前折未见人员。人员特征和窗口依赖可能共同影响差异，但本实验没有重新构造非重叠窗口，也没有控制所有样本组成因素，因此不把表 5 的差值全部归因为单一机制。

5.4　活动类别误差与人员差异

图 4 为全特征 FisherLDA 的测试混淆矩阵。2947 条窗口中正确 2836 条，错误 111 条；实际为

坐而预测为站立有 55 条，反向有 22 条，二者合计占错误的 69.37%。因此，该模型的剩余误差集中在部分静态姿态之间，不能仅用总体准确率概括所有活动的识别能力。姿态信号差异较弱是可讨论的解释，但本实验没有通过原始信号干预证明具体生理或采集原因。

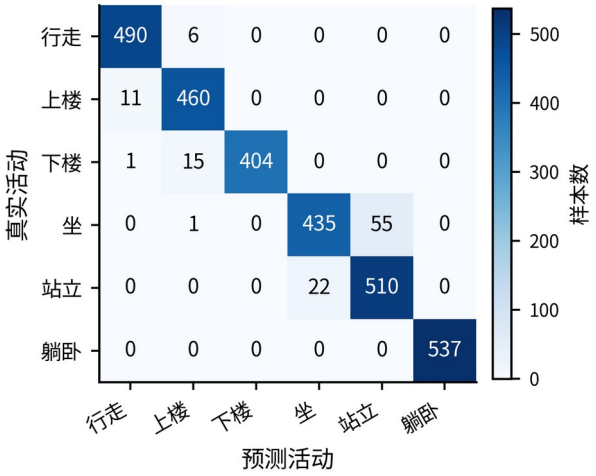


图 4　全特征 FisherLDA 的测试混淆矩阵

九名测试人员中，全特征 FisherLDA 最差人员为编号 10，其 Macro-F1 为 88.79%；人员等权平均为 95.97%。图 5 分别给出各人员在三条特征路径上的得分。总体 Macro-F1 接近高分并不意味着每名新用户都获得相同体验，也不能认为总体损失在 1 个百分点内就代表每个人都达标。

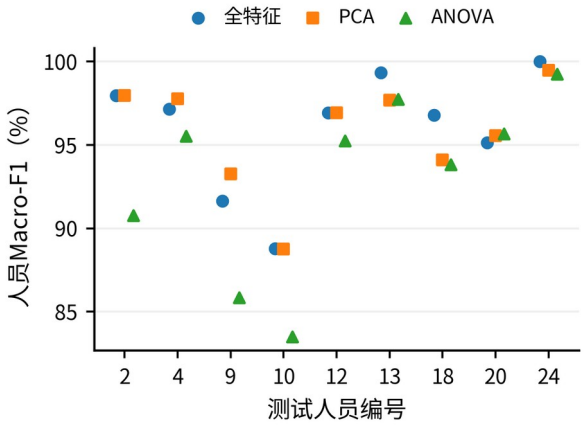


图 5　FisherLDA 在九名测试人员上的表现

表 6　PCA 相对全特征的人员等权 F1 差值

模型	平均差值(pp)	描述性 95%区间
SVM	-1.28	[-2.20, -0.54]
RF	-3.43	[-6.78, -0.35]
LR	-1.06	[-1.96, -0.34]
KNN	-0.32	[-0.96, +0.27]
LDA	-0.25	[-1.08, +0.53]

表 6 采用人员配对重采样，不把 2947 个相关窗口当作 2947 个独立实验对象。区间仅反映九名已测人员在固定模型下的变动，不能证明所有人群上等效、非劣效或显著优越；尤其不能把包含 0 的区间解释为已证明两方案相同。

6　预测开销与模型体积

6.1　相同批量下的完整流程比较

本节统一使用新加入的分阶段测时中 whole 调用结果，批量为 2947，并计入标准化、投影或选列和分类。这样不会把旧电脑的时间或分类器单独预测时间拼入完整流程。表 7 中的速度比为全特征耗时除以 PCA 耗时；小于 1 表示变慢。原有总体计时另存于 timing_summary.csv，由于执行顺序和缓存状态不同，两套测量数值不要求完全相等。

表 7 完整预测耗时与完整模型保存大小

模型	PCA 维数	全特征 μs/窗	PCA μs/窗	速度比	全特征 MiB	PCA MiB
SVM	150	349.393	157.903	2.21	6.311	2.369
RF	200	16.603	31.203	0.53	2.174	7.917
LR	200	1.911	7.245	0.26	0.037	0.834
KNN	150	205.714	79.713	2.58	28.324	8.756
LDA	300	1.758	9.874	0.18	2.243	1.907

注：耗时为 15 次完整 predict 调用的每窗口时间中位数；各模型分别使用验证锁定的参数与维数。MiB=2^{20} 字节；文件包含预处理，压缩等级相同，不代表峰值内存。

表 8 全特征与 PCA 的独立阶段中位数（μs/窗口，B=2947）

模型	特征方案	标准化	压缩变换	分类器	完整 predict
SVM	全特征	1.210	0.000	355.352	349.393
SVM	PCA	1.225	4.678	154.151	157.903
RF	全特征	1.067	0.000	15.796	16.603
RF	PCA	1.217	5.905	24.622	31.203
LR	全特征	1.172	0.000	1.047	1.911
LR	PCA	1.127	5.750	0.343	7.245
KNN	全特征	1.173	0.000	207.574	205.714
KNN	PCA	1.157	4.579	73.890	79.713
LDA	全特征	1.122	0.000	1.028	1.758
LDA	PCA	1.143	8.132	0.498	9.874

注：各阶段在预先准备的输入上独立测量，因此表中前三阶段之和不是严格意义的完整时间分解。全特征压缩变换的 0 表示操作不存在。ANOVA 完整记录见 stage_timing_summary.csv。

同一测时口径下，PCA 使 SVM、KNN 的完整批量预测加快，使 RF、LR、LDA 变慢。这个结论不是仅由维数计算出来的，而是来自完整 Pipeline 的重复调用。压缩率高并不必然对应模型更小，保存的投影矩阵、树结构与训练参考样本也会占用空间。

6.2 分类机制与变换成本

对于 RBF-SVM，预测需要计算输入与支持向量之间的核值；对于暴力 KNN，预测涉及输入与训练参考样本的距离。降低维数可能减少每次比较的算术量，从而抵消 PCA 投影开销，但支持向量数量、输入布局和批量也参与影响。图 6 用真实阶段测量展示 SVM 的这种权衡，而不是假设所有维数都以同一比例节省时间。

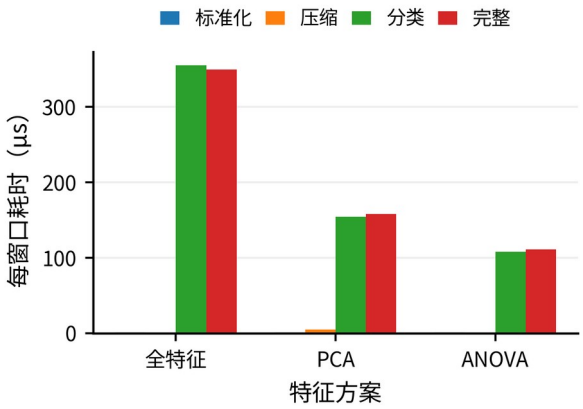


图 6 SVM 的独立阶段与完整预测耗时

LR 与 LDA 的最终判别本来就是线性运算。对于 B 个样本、d 个输入特征与 C 个类别，主要判别运算量与 B·d·C 相关；PCA 额外投影则与 B·d·k 相

关。在本任务 C=6、k 远大于 6 的设置下，额外投影可能比原先分类计算更重。图 7 可以检查这一解释是否与实测阶段量级一致，但不能把独立阶段中位数相加后再作精确因果归因。

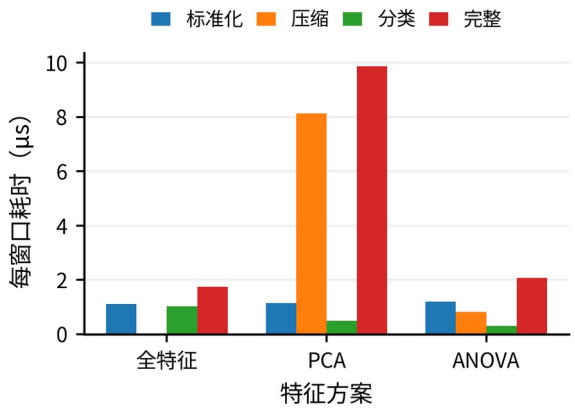


图 7　FisherLDA 的独立阶段与完整预测耗时

随机森林预测主要沿若干树路径遍历，输入维数下降不意味着树数、路径长度或节点总数同比下降。PCA 改变了坐标表示，树的切分方式也可能变化。本文将这些因素视为合理机制解释而不是单因素因果证明。尤其是 max_features=sqrt 随维数变化，压缩模型和全特征模型的内部随机子空间不完全相同。

ANOVA 只执行列子集提取，没有 PCA 的稠密投影，但索引、复制和输入检查仍有成本；且保留相同数量的原始列不保证相同分类信息。其各模型的完整时间与体积另列于附录表 A3，避免只讨论 PCA 而遗漏另一条压缩路线的资源结果。

6.3　批量规模与延迟口径

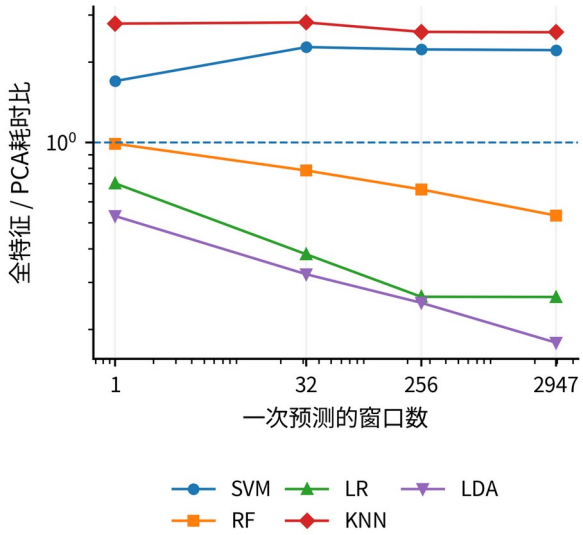


图 8　不同批量下 PCA 相对全特征的速度比

图 8 同时保留小批量和大批量。函数调用与输入校验等固定开销，在 B=1 时不能被许多窗口分摊；较大批量则可以使用矩阵运算及缓存。各分类器的曲线可能不同，不能只报告最有利的最大批量结果。由于不同批量取不同固定子集，且树路径和邻居搜索也受输入影响，图 8 不是仅由批量这一变量引起的严格因果估计。

本次测量中，SVM 在 B=1 和 B=2947 时的速度比分别为 1.69 和 2.21；KNN 在 B=1 和 B=2947 时的速度比分别为 2.78 和 2.58；LDA 在 B=1 和 B=2947 时的速度比分别为 0.53 和 0.18。B=1 只对应测试窗口 0，不能据此报告线上所有用户的尾延迟。原有 64 位置单窗口循环计时提供了另一组描述性测量，但并非这里 B=1 的同义指标。

6.4　训练成本与预测成本分开讨论

压缩需要额外拟合变换器。主搜索中，同一训练折的标准化、PCA 和 ANOVA 评分跨分类器复用，降低的是重复搜索的工程开销，并没有减少 2400 次候选分类器拟合。cv_candidates.csv 中的分类器拟合时间不是每条完整管线独立从头训练时间，也不包含测试后的阶段计时。最终模型的 final_fit_seconds 则包含完整训练集上的预处理、变换和分类器拟合，两者不能混用。

五个模型全特征/PCA 最终拟合秒数依次为：SVM 0.790/1.169；RF 21.496/18.400；LR

1.446/1.824；KNN 0.031/0.804；LDA 0.191/0.683。这些拟合时间各测一次，只能作为运行记录，不作为稳定的训练加速结论。以文件大小或预测速度替代训练耗时，同样会改变所评价的问题。

7 讨论与有效性威胁

7.1 为什么“少特征”不是统一目标

对于已经具有较小预测开销的线性分类器，先选择合适的分类机制，可能比额外增加 PCA 更划算；对于保存许多参考样本或支持向量的模型，低维表示可能明显改变距离计算与存储成本。因而方案选择应在准确率、人员差异、输入维数和完整开销之间作权衡，而不应把“维数越少”设为唯一成功标准。测试后的帕累托表仅用于描述这组结果，不能取代测试前锁定的配置选择。

对线性末端分类器，标准化、PCA 和线性判别在数学上都是仿射运算，原则上可合并为一个等效权重矩阵。本次未实现算子融合，测量的是现有 scikit-learn Pipeline 执行方式；因此，观察到的 PCA 额外开销不意味着任何优化部署都必然具有同样成本。另一方面，PCA 仍需要本项目的 561 维输入，不能把压缩后较小的向量称为已经减少了传感器端特征提取工作。

7.2 统计与研究过程的限制

首先，官方测试集在本课题前期探索中已经查看过。本轮虽重新运行全部候选、在程序中维持先锁定后测试，仍属于扩展探索性复现，不是从未接触的新外部确认。本轮网格在执行前固定，未根据本轮测试挑选参数；但本地配置锁定并不将整个研究过程变为正式预注册。

其次，只有九名测试人员，不能把窗口数当作独立用户数来夸大证据。单次官方划分不覆盖不同年龄、佩戴位置、设备和真实环境。所有新增步骤均按人员折内拟合，但官方上游归一化的拟合范围无法仅凭特征文件确认。因此，本项目对自身数据处理边界作出保证，而不声称完成了原始数据生成链条的全面审计。

再次，有限网格并非全局最优；PCA 与 ANOVA 也不是所有压缩方法的代表。重新调参后比较的是完整管线，变化不完全由单一压缩步骤造成。ANOVA 单变量评分不主动去冗余，也不直接优化跨人员稳定性；本文没有执行互信息、递归消除或稳定性筛选，所以不能声称 ANOVA 最适合该任务。

最后，性能容忍值 0.01 是工程设定，并非具有临床或生产安全意义的界限。折间标准差、人员 Bootstrap 区间和几次同环境复算各有不同范围，不能混为统计显著性保证。计时受虚拟化 CPU、内存布局、缓存与库实现影响，模型文件体积不等于运行内存，更不代表手机功耗。

7.3 实验记录与可复查性

本次新增计时任务与原训练流程解耦：它只在最终模型锁定和测试后执行，不改变参数或成绩。检查记录覆盖配置与数据哈希、人员隔离、候选数量、选择规则、逐窗口指标复算、模型文件一致性和阶段预测一致性。阶段预测共比较 48,540 个窗口输出，检验拆解是否改变模型语义；软件测试用的小型夹具不作为 HAR 效果数据。

53 项软件测试通过。完成主实验后，另外重新拟合 15 条已锁定管线，44,205 条测试预测与本轮保存记录一致；这不是整个 2400 次参数搜索重复执行。相同环境的复算可检查软件实现，但本地日志和哈希不是不可篡改的第三方证明，跨 Python 或数学库版本也不保证逐位一致。本文主结果均来自 outputs/integrated_rerun，旧表仅作版本追溯，旧计时不进入结论。

与上传旧包比较，新增 250 维并未改变 15 条最终管线的选定参数、维数和验证达标标记。但是，共同候选的 2080 条折记录中，逻辑回归有 191 条 Macro-F1 记录在两次环境间存在超过 10^{-10} 的差异，最大绝对差为 3.186 个百分点；其他四类模型的共同折分数一致。旧记录使用 Python 3.11.17，本次为 3.13.5，执行环境并不相同。相应核心算法源文件与原始数据哈希一致，但本研究尚未通过受控实验确定差异的具体原因，不能据此断言差异由新增维数、随机种子或某一数学库单独造成。对于差异最大的 ANOVA300/C=100 候选，第

0 折在本环境重新执行缓存实现与标准 Pipeline，Macro-F1 均为 92.497%，与本轮记录一致。本文仍使用新计算的逻辑回归成绩，不将旧值改写成本次结果，也不宣称跨环境逐位复现。

8 结论

本文在官方人员隔离划分上完成五分类器、全特征/PCA/ANOVA 三条路径的统一比较，重新运行 480 组候选和 2400 次主要五折拟合。总体测试结果中，全特征 FisherLDA 得到 96.26%的 Macro-F1。不同人员及活动之间仍有差异，随机窗口验证也不能替代人员独立评价，回答了 R1 关于评价目标的问题。

对于 R2，PCA 与 ANOVA 的收益依赖分类器，压缩路线中 3 条未达到训练验证容忍范围。即使验证达标，未见人员测试也可能超过预定损失。所选维数只能理解为候选集合内按既定规则的结果，不能推广为通用最优维数；ANOVA 提供了可解释的原始列筛选对照，但没有被证明优于其他选择方法。

对于 R3，本轮在四种批量下测量完整流程及独立阶段；最大批量下 PCA 对 SVM、KNN 产生预测加速，对 RF、LR、LDA 增加完整时间。由此，降维不应被当作普遍有效的加速步骤。后续可在新的人员数据上确认结论，并单独研究线性管线融合或传感器端选特征实现；这些内容尚未在本文完成，不能作为已有贡献。

参考文献

[1] Anguita D, Ghio A, Oneto L, Parra X, Reyes-Ortiz J L. A public domain dataset for human activity recognition using smartphones//Proceedings of the 21st European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning. Bruges, Belgium, 2013: 437–442.

[2] Reyes-Ortiz J, Anguita D, Ghio A, Oneto L, Parra X. Human Activity Recognition Using Smartphones [Dataset]. UCI Machine Learning Repository, 2013. DOI: 10.24432/C54S4K.

[3] Dehghani A, Sarbishei O, Glatard T, Shihab E. A quantitative comparison of overlapping and non-overlapping sliding windows for human activity recognition using inertial sensors. Sensors, 2019, 19(22): 5026.

[4] Jolliffe I T, Cadima J. Principal component analysis: a review and recent developments. Philosophical Transactions of the Royal Society A, 2016, 374(2065): 20150202.

[5] Guyon I, Elisseeff A. An introduction to variable and feature selection. Journal of Machine Learning Research, 2003, 3: 1157–1182.

[6] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 2011, 12: 2825–2830.

[7] Cortes C, Vapnik V. Support-vector networks. Machine Learning, 1995, 20: 273–297.

[8] Breiman L. Random forests. Machine Learning, 2001, 45: 5–32.

[9] Cover T, Hart P. Nearest neighbor pattern classification. IEEE Transactions on Information Theory, 1967, 13(1): 21–27.

[10] Fisher R A. The use of multiple measurements in taxonomic problems. Annals of Eugenics, 1936, 7(2): 179–188.

[11] Scikit-learn developers. LogisticRegression. Scikit-learn 1.8.0 documentation [EB/OL]. [2026-10-27].

[12] Scikit-learn developers. StratifiedGroupKFold. Scikit-learn 1.8.0 documentation [EB/OL]. [2026-10-27].

[13] Scikit-learn developers. Common pitfalls and recommended practices. Scikit-learn 1.8.0 documentation [EB/OL]. [2026-10-27].

[14] Scikit-learn developers. LinearDiscriminantAnalysis. Scikit-learn 1.8.0 documentation [EB/OL]. [2026-10-27].

[15] Scikit-learn developers. Computational performance. Scikit-learn 1.8.0 documentation [EB/OL]. [2026-10-27].

附录 A　运行证据与文件对应关系

表 A1　本次运行与测量信息

项目	记录
运行目录	outputs/integrated_rerun
开始时间（UTC）	2026-10-27T08:13:21.607482+00:00
结束时间（UTC）	2026-10-27T08:41:24.588903+00:00
本次主网格	480 候选；5 折；2400 次拟合；无旧断点复用
验证与测试	50 次固定参数协议拟合；15 条最终管线
分阶段测时	15 管线 × 4 批量 × 4 阶段 × 15 轮＝3600 记录
计时输入一致性	60 组；48,540 个输出；结果见 stage_timing_verification.json
软件环境	Python 3.13.5 / sklearn 1.8.0 / NumPy 2.3.5 / SciPy 1.17.0
计时处理器	AMD EPYC 9V74 80-Core Processor

表 A2　正文证据索引（相对运行目录，特别注明的项目根目录除外）

内容	源文件
表 1、数据描述	data_audit.json；splits/official_test.csv
表 2、方法设置	config_frozen.json；search_plan.json
表 3、选择与测试	tables/selected_configs.csv；tables/test_metrics.csv
图 1～2、表 4	tables/compression_curve.csv；tables/cv_candidates.csv
表 5、图 3	tables/protocol_comparison.csv
图 4～5、表 6	tables/test_predictions.csv；test_subjects.csv；subject_bootstrap.csv
表 7～8、图 6～8	tables/stage_timing_summary.csv；stage_timing_raw.csv；final_fit_and_size.csv
核验结论	verification.json；stage_timing_verification.json；validation/
整合差异	provenance/notebook_merge_diff.json；docs/Notebook 整合说明.md

表 A3　ANOVA 路径的完整预测与体积（批量 2947）

模型	维数	测试 F1(%)	ΔF1(pp)	μs/窗口	速度比	MiB
SVM	200	93.60	-1.86	111.440	3.14	1.235
RF	200	89.84	-2.71	15.686	1.06	2.315
LR	200	93.77	-1.74	1.999	0.96	0.026
KNN	100	86.90	-1.78	55.874	3.68	4.586
LDA	200	93.61	-2.65	2.075	0.85	0.272

原始结果 CSV 保留足够的小数位，正文为便于阅读进行了四舍五入；容忍规则和核验均使用未四舍五入值。完整图片在运行目录 figures 中，本文选用部分图并按双栏尺寸重绘，数值未改变。作者姓名、单位及学号未提供，题录中仅保留待填写位置，没有虚构基金、收稿日期、卷期或 DOI。

表 A4　15 条最终管线的实际选定参数

模型与方案	维数	分类器参数（其余设置见正文）
SVM / 全特征	561	C=10.0；gamma=0.001
SVM / PCA	150	C=10.0；gamma=0.001
SVM / ANOVA	200	C=100.0；gamma=0.001
RF / 全特征	561	max_depth=20；min_samples_leaf=3
RF / PCA	200	max_depth=None；min_samples_leaf=1
RF / ANOVA	200	max_depth=None；min_samples_leaf=1
LR / 全特征	561	C=1.0
LR / PCA	200	C=1.0
LR / ANOVA	200	C=1.0
KNN / 全特征	561	n_neighbors=15；weights=distance
KNN / PCA	150	n_neighbors=15；weights=distance
KNN / ANOVA	100	n_neighbors=15；weights=uniform
LDA / 全特征	561	shrinkage=None
LDA / PCA	300	shrinkage=auto
LDA / ANOVA	200	shrinkage=None

附录 B　复现步骤

安装 requirements.txt 中的固定依赖后，在项目根目录运行 python run_experiment.py --out outputs/new_run --workers 4。只显示规模可使用 --plan；中断后用 --resume outputs/new_run 恢复。恢复期间不得更改输入数据、配置、源代码和软件版本，以免混用不一致的折级断点。训练会自动执行新增分阶段计时和核验。

已有完整运行只重画图时，执行 python redraw_figures.py --run outputs/integrated_rerun；复算结果使用 python verify_results.py --run outputs/integrated_rerun。仅补测阶段开销时运行 measure_stages.py，并注意另存原计时以保留历史。Notebook 入口使用同目录数据和同一套模块，不再内嵌 41MB 数据编码。

本文版式参考公开的计算机学报模板体例，采用中英文题录、摘要、关键词、双栏正文、公式编号、三线表和顺序编码参考文献；这是课程报告初稿，不是期刊接收或发表版本。用于进一步修改的 Markdown 和 Word 源稿、结果证据表、文献链接清单随项目提供。